Datamurskaamo backlog (voit kopioida suoraan)

Vaihe 1 – ympäristö

- WSL + Ubuntu käyttöönotto
- Neovim kehitysympäristön rakentaminen
- Copilot-integraatio
- Python-ympäristön pystytys (venv)

Vaihe 2 – datan käsittely

- PDF-tiedostojen lukeminen (pypdf)
- tekstin yhdistäminen
- tekstin siistiminen

Vaihe 3 – analyysi

- tekstin pilkkominen (chunking)
- embeddingien luonti
- FAISS-hakuindeksi

Vaihe 4 – tekoäly

- LLM (Ollama)
- kysymys → kontekstihaku → vastaus
- usean dokumentin yhdistäminen

Vaihe 5 – käyttöliittymä (optional mutta kova)

- CLI käyttö
- mahdollinen web UI (future)

Step 1 – projekti pystyyn

Aja:

```
mkdir ~/datamurskaamo
cd ~/datamurskaamo
```

luo virtuaaliympäristö:

```
python3 -m venv venv
source venv/bin/activate
```

Step 2 – asennetaan kirjastot

```
pip3 install pypdf sentence-transformers faiss-cpu ollama
```

(ollama tulee myöhemmin käyttöön AI:lle)

Step 3 – testi PDF-luku

luo tiedosto:

```
nvim main.py
```

ja laita:

```
from pypdf import PdfReader

reader = PdfReader("test.pdf")

text = ""
for page in reader.pages:
    text += page.extract_text() + "\n"

print(text[:1000])
```

laita samaan kansioon joku PDF nimellä:

test.pdf

aja:

```
python3 main.py
```

👉 jos saat tekstin ulos → pipeline toimii

Seuraava vaihe

Kun tämä toimii, seuraavaksi:

- liitetään **LLM (Ollama)**
- kysytään:
  “Mitä tämä dokumentti kertoo?”
- ja saadaan vastaus useasta PDF:stä

Tärkeä pointti

Tämä tulee olemaan:

- täysin **lokaali**
- ei pilveä
- ei datan vuotoa
- toimii sun RTX-koneella 🔥

Kun saat tuon PDF-testin toimimaan, sano:

👉 **“jatketaan AI-vaiheeseen”**

niin liitetään siihen oikea “äly” mukaan.